

# 視覚と行動の end-to-end 学習により経路追従行動を オンラインで模倣する手法の提案

-トポロジカルマップとシナリオに基づく経路選択機能の追加と検討-

○春山健太（千葉工大），藤原恆（千葉工大）馬場琉生（千葉工大）

石黒巧（千葉工大）上田隆一（千葉工大）林原靖男（千葉工大）

## A proposal for an online imitation method of path-tracking behavior by end-to-end learning of vision and action - Adding and consideration of path selection function based on a topological map and scenario -

○ Kenta HARUYAMA (CIT), Masaki FUJIWARA (CIT), Ryusei BABA (CIT),

Takumi ISHIGURO (CIT), Ryuichi UEDA (CIT), Yasuo HAYASHIBARA (CIT)

**Abstract:** We proposed an online imitation of path-following behavior based on end-to-end learning of vision and behavior. In this study, the robot moves autonomously to the destination based on camera images and target directions. In this paper, we add a method to generate target directions from camera images. We introduce a method for autonomous movement to a destination based on camera images without requiring a metric map. Experiments using a real robot verify the effectiveness of the proposed method.

### 1. 緒言

本研究グループでは、LiDARなどをセンサ入力とする行動をカメラ画像を入力とする行動へ模倣することで、ロボットに複数のナビゲーション手段を与える手法を提案してきた[1][2]。これまで提案した手法では、LiDAR やオドメトリ、事前に作成したメトリックマップを入力とする地図に基づいたルールベース制御器によって経路追従する。ここでいう地図に基づいたルールベース制御器は ROS Navigation Stack[3] であるその際、この行動をカメラ画像と進行方向の情報（以後、目標方向と呼ぶ）を入力としてオンラインで模倣するように学習する。これにより、Fig.1 に示すカメラ画像と前述のルールベース制御器から生成される目標方向に基づき、経路を選択して追従する行動を獲得できる。

前報[1][2]では Fig.1 のようにカメラ画像から目標方向を生成していなかった。そこで、カメラ画像に基づいて目標方向を生成する方法を検討する。本稿では、カメラ画像から目標方向を生成する方法として、島田ら[4]が提案したトポロジカルマップと「条件」や「行動」による経路の表現（以後、シナリオと呼ぶ）をこれまで提案した手法へ追加する。そして、カメラ画像とトポロジカルマップから生成されるシナリオに基づいて、目的地まで自律移動する手法を新たに提案する。この手法により、事前に作成したメトリックマップを必要せずに、カメラ画像を入力として目的地まで自律移動できる可能性がある。

メトリックマップを用いず、カメラ画像に基づいて自律移動を行う研究はいくつある。Dhruv ら[5]は大規模な事前学習モデルを用いて、自然言語による指

示から、画像によるナビゲーションを end-to-end で行う手法を提案している。また miyamoto ら[6]はカメラ画像と深層学習による走行可能領域の検出とトポロジカルマップを用いたナビゲーション手法を提案している。これらの手法では、補助的ではあるが、Global Navigation Satellite System (GNSS) やホイールオドメトリといった情報を必要とすることが本稿で提案する手法との違いに挙げられる。本稿では、提案手法の有効性を実ロボットを用いた実験により検証すること目的とする。

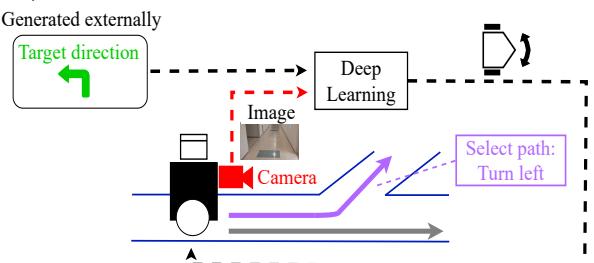


Fig.1 Path selection and following behavior based on camera images and target direction by imitation learning.

### 2. 提案手法

提案する手法では、人間が作成した「次の角まで直進、左折」などのシナリオから指示される道順に従い、カメラ画像に基づいて目的地まで自律移動する。本章では手法の流れについて述べた後、それぞれのモジュールの詳細を述べる。

Fig.2 に提案手法の概要と一連の流れを示す。提案手法は、1) シナリオを分解し、「条件」と「行動」を

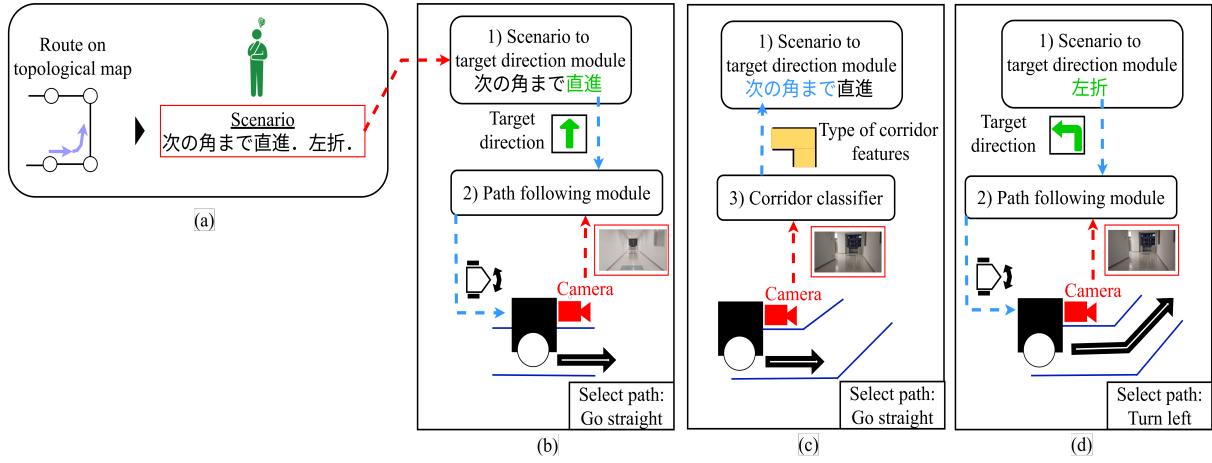


Fig.2 Overview of proposed method

抽出するモジュール 2) カメラ画像と目標方向に基づく経路追従モジュール 3) シナリオの「条件」の判定に用いる、通路の特徴を分類する通路分類器の 3 つのモジュールで構成される。はじめに、人が作成したシナリオがモジュールへ入力される。自律移動時はロボットに取り付けたカメラから得た画像データを入力とする

一連の流れを下記に示す

- (a)トポジカルマップ上の経路から人が「条件」と「行動」で構成される経路の表現(シナリオ)を生成する。生成されるシナリオ:「次の角まで直進. 左折。」
- (b)生成されたシナリオを句点ごとに区切り、次に「条件」と「行動」を抽出する。1つ目の区切りでは条件:次の角まで、行動:直進が登録される経路追従モジュールは、カメラ画像に基づいて、経路に沿って直進する。
- (c)角の部分に到達し、カメラ画像に基づく通路分類の結果が角となり、「次の角まで」というシナリオの条件が満たされた場合、2つ目の区切りへ遷移する。
- (d)2つ目の区切りでは行動:左折が登録され、経路追従モジュールは経路に沿って左折する。

## 2.1 カメラ画像と目標方向に基づく経路追従

カメラ画像と目標方向に基づいて、経路を追従するモジュールについて述べる。このモジュールは、地図を用いたルールベース制御器の出力を模倣するように学習して、カメラ画像に基づいた経路追従行動を獲得する[1][2]。これにより、学習後はRGBカメラのみのセンサ入力で経路追従が可能である。

Fig.3 に経路追従モジュールのシステムを示す。学習時は、2D-LiDAR やオドメトリ、事前に作成したメトリックマップに基づいたルールベース制御器 (ROS Navigation Stack[3]) によって、設定した経路を走行する。その際、入力をカメラ画像、目標方向、出力をヨー方向の角速度(地図を用いたルールベース制御器が出力)として、0.2 秒周期でデータセットに加える。さらに、バッチサイズを 8 として教師データをデータセットから抽出し、0.2 秒の周期でオンラインで学習する。このデータセットにデータを追加、データの抽出、学習の 1 連の流れを 1 ステップとする。ここで目標方

向は、地図に基づいたルールベースの制御器から出力される信号を用いる。データセットの収集には、藤原ら[2]が提案したデータセットの不均衡の改善、学習時における積極的な蛇行といった最も経路追従の成功率の高い手法を採用する。

学習後、カメラ画像と後述するシナリオを解釈し、変換するモジュールから目標方向を与える。出力されるヨー方向の角速度によりロボットを制御する。このとき、並進速度には 0.2m/s の一定の値を与える。

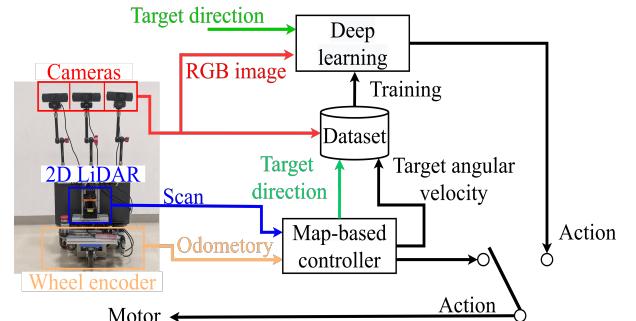


Fig.3 Imitation learning system with target direction

## 2.2 シナリオから目標方向への変換

シナリオから経路追従モジュールが必要とする目標方向を出力するモジュールについて述べる。このモジュールはトポジカルマップから作成されたシナリオから「突き当たりまで」という「条件」や「直進」などの「行動」を解釈し、単語で構成された経路を目標方向へ変換して出力する。後述する分類器と組み合わせることで、目的地までの自律移動に必要な目標方向を、メトリックマップを用いずに、経路追従モジュールへ与えることを可能とする。

Fig.4 にトポジカルマップの例とそれを基に生成されるシナリオを示す。トポジカルマップは通路の特徴的な箇所に配置されたノード (Fig.4 青), これらをつなぐエッジ (Fig.4 緑) で構成される。ノードは ID, 通路の特徴、接続されるエッジとその方向のデータが含まれ、エッジには ID のデータのみが含まれている。シナリオはトポジカルマップ上で目的地までの経路を「条件」と「行動」に関する単語を組み合わせによって表現したものである。Fig.4 のトポジカルマップとシナリオを生成する例を示す。この例では出発地

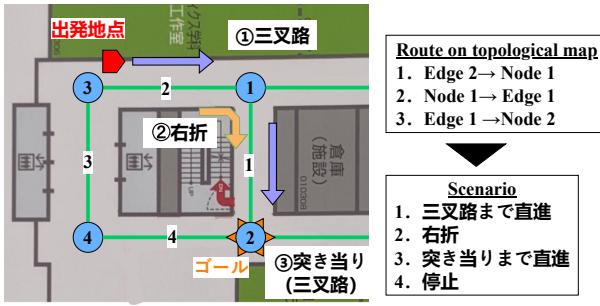


Fig.4 Example of topological map and generated scenario

点をエッジ 2、目的地をノード 2 として、エッジとノードを経由していく。エッジ 2 からノード 2 までの経路はエッジ 2 からノード 1 は「三叉路まで」という条件と「直進」という行動、ノード 1 からエッジ 1 は「右折」という行動、エッジ 1 からノード 1 は「突き当たり(三叉路)まで」という条件と「直進」の行動で表現される。これらを統合すると、最終的に「三叉路まで直進、右折、突き当たりまで直進、停止」が生成される。

次に生成されたシナリオを目標方向として変換する方法を述べる。目標方向への変換ではシナリオを句点ごとに分解後、「条件」と「行動」を示す言葉を抽出し、以下の項目に分けて登録する。

- 1) 通路の特徴
- 2) 順番
- 3) 方向
- 4) 行動

シナリオの例は句点ごとに三叉路まで直進/ 右折/ 突き当たりまで直進/ 停止/ と区切られる。1つ目の区切りでは

- 1) 通路の特徴：三叉路
- 4) 行動：直進

2つ目の区切りでは

- 4) 行動：右折

が登録される。この一連の作業を末尾の区切りである「停止」が登録されるまで行う。ここで登録される「行動」を目標方向として、前述の経路追従モジュールへ与える。目標方向のデータ形式を Table 1 に示す。ここで、「三叉路まで」といった条件を満たしたかの判定は後述する通路分類器を用いて行う。

Table 1 Target direction and data for imitation learning

Target direction	Data
Go straight	[1, 0, 0]
Turn left	[0, 1, 0]
Turn right	[0, 0, 1]
Stop	[0, 0, 0]

### 2.3 通路の特徴を分類する通路分類器

シナリオで用いる「条件」を満たしたかの判定に必要な通路の特徴を、カメラ画像と深層学習によって分類する通路分類器について述べる。このモジュールは RGB カメラのみのセンサ入力で通路の特徴を分類することが可能である。通路分類器の概要を Fig.5 に示す。通路分類器はフレーム数 16 の連続した画像データ(画像サイズは  $64 \times 48$ )を入力とし、通路の特徴の分類を出力する。通路の特徴の分類は島田らの手法 [4] に倣い、Fig.6 に示した 8 つとする。この通路分類器の

ネットワークアーキテクチャは Dhaivat らが提案する CNN と LSTM を組み合わせた LRCN[7] を参考として構築した。なおシステムでは、CNN アーキテクチャに MobileNetV3-Large[8] を用いている。

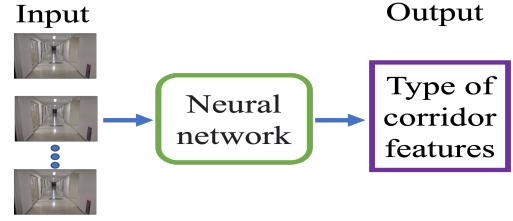


Fig.5 Types of corridor features classifier overview

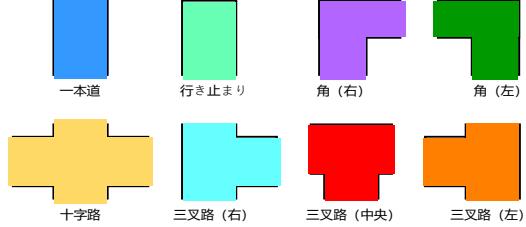


Fig.6 Types of corridor features

次に分類器のデータセットの作成について述べる。データの作成では、地図に基づいたルールベース制御器によって経路を走行し、その際、フレーム数 16 の連続したカメラ画像と通路の分類ラベルを 1 組とし、0.125 秒周期でデータセットへ加える。その際、分類ラベルのアノテーションは、Fig.7 に示す地図上で対応した分類ラベルを生成する機能を追加した地図に基づいたルールベース制御器の出力を用いて、自動的に行う。

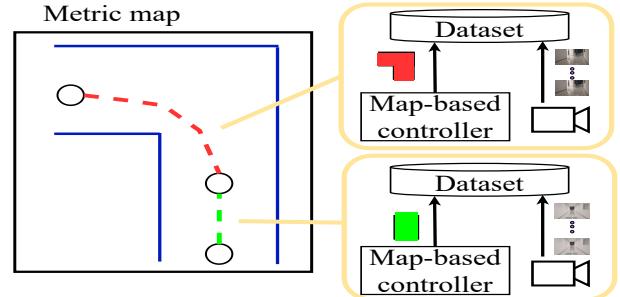


Fig.7 Types of corridor features

学習に用いるデータセット内で、各クラスのデータ数が大きく異なる不均衡データは、分類に大きな影響を与える [9] とされている。そのため、本稿では学習する際に、データセット内のクラス間のデータ数によって重み付けを行うコストアプローチ [10] を導入している。

## 3. 実験

実ロボットを用いて、提案するカメラ画像とシナリオに基づく経路追従手法により、ロボットが目的地へ到達可能であるか検証する。

### 3.1 実験装置

実験には Fig.8 で示すカメラを 3 つ搭載したロボットを使用する。

### 3.2 実験方法

実験環境として Fig.9 で示した千葉工業大学津田沼キャンパス 2 号館 3 階の廊下を用いる。経路追従モ

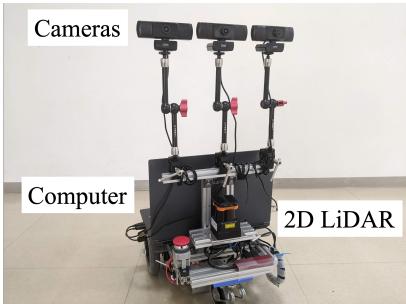
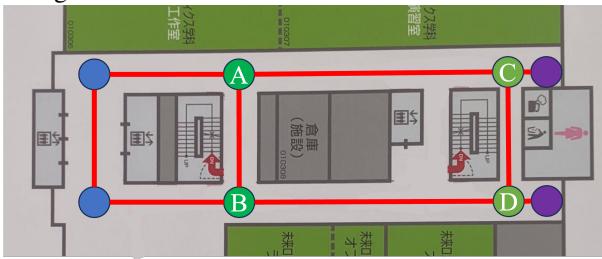


Fig.8 Experimental setup

ジユールの訓練および通路分類器のデータセット収集では Fig.10 で示した a から n の経路を順番に走行する。実験では島田らが用いた 50 例のシナリオの中から、7 例を用いた。選定の基準は、Fig.9 の場所を対象としていること。ロボットが移動困難な狭い通路が含まれていないこと。「後ろを向く」など経路追従モジュールができる行動が含まれていないことである。まずははじめに通路分類器の訓練を行う。前述の経路を地図に基づいたルールベース制御器の出力を用いて、3 周し、データセットを収集する。収集したデータは、1, 2 周目を訓練データとし、3 周目をテストデータとする。それぞれのデータ数は、訓練データ 5781, テストデータ 2902 である。訓練はバッチサイズを 32 として、30epoch 行った。訓練の結果、テストデータに対する Accuracy は 0.98 であった。

次に経路追従モジュールの訓練を行う。通路分類器の訓練と同様の経路を、オンラインで模倣学習しながら 1 周走行する。その際のステップ数は 12000 であった。

2 つのモジュールを訓練後、1 例のシナリオをシステムに入力する。この入力したシナリオのスタート地点へロボットを配置し、目的地までの自律移動を開始する。Fig.11 に実験で用いた 7 例のシナリオを示す。



●: 3-way intersection ●: Corner ●: Dead end

Fig.9 Experimental environment

### 3.3 実験結果

Fig.12 に Fig.11(f) における経路追従の様子を示す。結果として、7 例すべての例でロボットが、指定された経路を追従して目的地へ到達した。以上の結果から、提案するカメラ画像とシナリオに基づいて、経路を追従して目的地まで自律移動する手法の有効性が確認された。

## 4. 結言

本稿では、事前に作成したメトリックマップを用いず、カメラ画像とシナリオに基づいて経路を追従して目的地まで自律移動する手法を提案した。そして、実ロボットを用いた実験により提案手法の有効性を検証

した。

## 参考文献

- [1] 春山 健太 et al.: “視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案”. ロボティクス・メカトロニクス講演会講演概要集 2022, 2P2-L05, (2022). doi: 10.1299/jsmermd.2022.2P2-L05.
- [2] 藤原征, 春山健太, 馬場琉生, 上田隆一, 林原靖男: “視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案 - 実環境における経路選択機能の検証と学習時間の短縮化の検討 - ”. 日本機械学会ロボティクス・メカトロニクス講演会'23 予稿集, 2P2-G06, (2023).
- [3] ROS Navigation Stack: *ROS Navigation Stack*. Accessed on 25.10.2023. URL: <https://github.com/ros-planning/navigation>.
- [4] 島田滉己, 上田隆一, 林原靖男: “トポロジカルマップを用いたシナリオによるナビゲーションの提案 - シナリオに基づく実ロボットのナビゲーション”. 計測自動制御学会 SI 部門講演会 SICE2020 予稿集, 1H2-04, (2020).
- [5] Dhruv Shah et al.: “LM-Nav: Robotic Navigation with Large Pre-Trained Models of Language, Vision, and Action”. *6th Annual Conference on Robot Learning*. 2022. URL: <https://openreview.net/forum?id=UW5A3SweAH>.
- [6] Ryusuke Miyamoto et al.: “Vision-Based Road-Following Using Results of Semantic Segmentation for Autonomous Navigation”. *2019 IEEE 9th International Conference on Consumer Electronics (ICCE-Berlin)*. 2019, pp. 174–179. doi: 10.1109/ICCE-Berlin47944.2019.8966198.
- [7] Dhaivat Bhatt et al.: “Have I reached the intersection: A deep learning-based approach for intersection detection from monocular cameras”. *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2017, pp. 4495–4500. doi: 10.1109/IROS.2017.8206317.
- [8] Andrew Howard et al.: *Searching for MobileNetV3*. (2019). arXiv: 1905.02244 [cs.CV].
- [9] Harsurinder Kaur, Husanbir Singh Pannu, and Avleen Kaur Malhi: “A Systematic Review on Imbalanced Data Challenges in Machine Learning: Applications and Solutions”. *ACM Comput. Surv.* 52.4, (Aug. 2019). ISSN: 0360-0300. doi: 10.1145/3343440. URL: <https://doi.org/10.1145/3343440>.
- [10] Jie Xu et al.: “Fault Diagnosis on Imbalanced Data Using an Adaptive Cost-sensitive Multiscale Attention Network”. *2021 International Conference on Intelligent Technology and Embedded Systems (ICITES)*. 2021, pp. 77–82. doi: 10.1109/ICITES53477.2021.9637101.

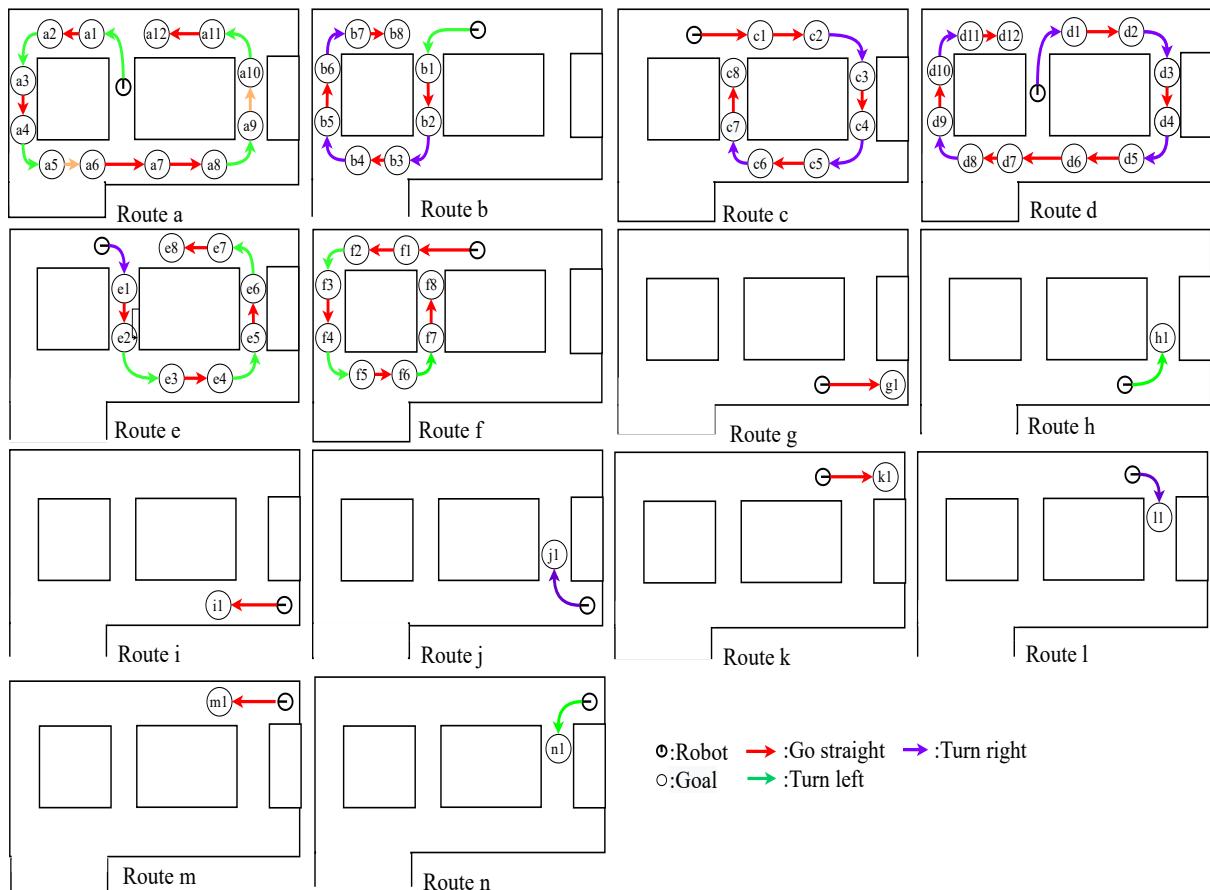


Fig.10 Route used for learning

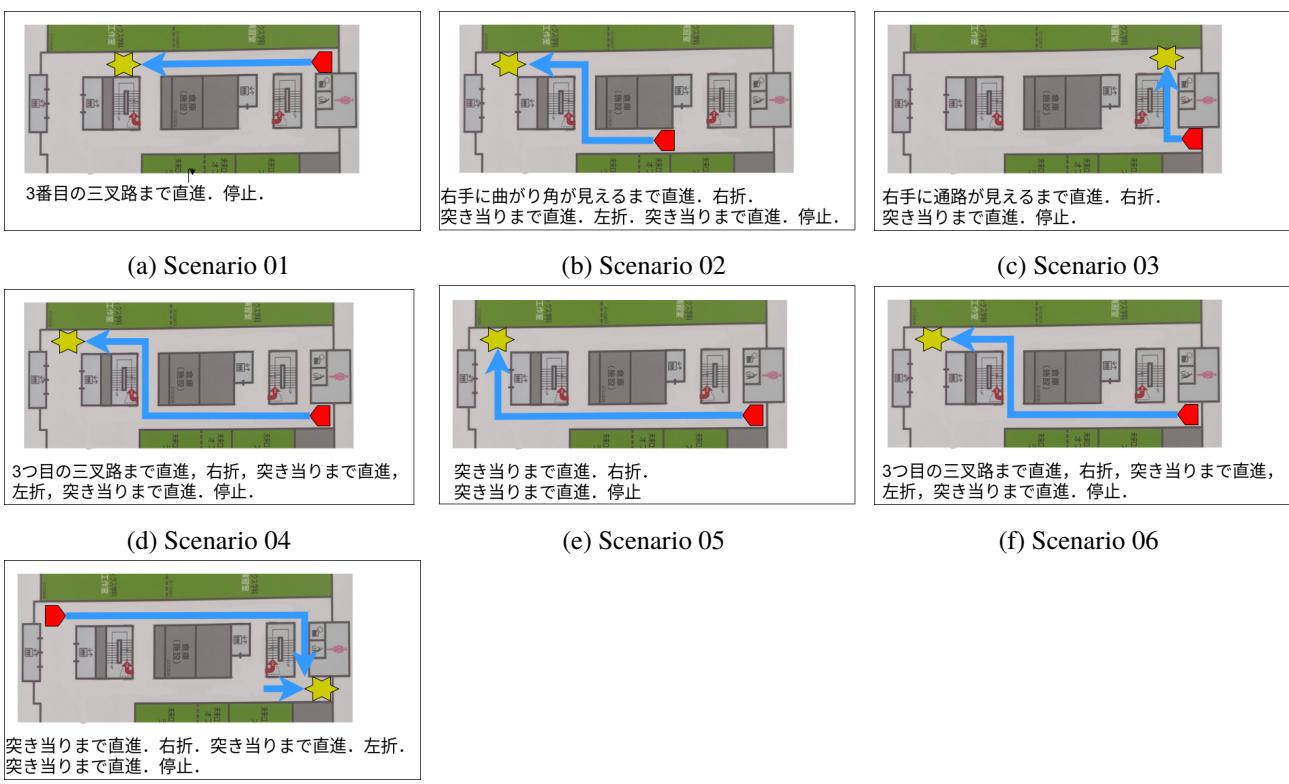


Fig.11 Scenario used in the experiment



(a) 3つ目の三叉路まで直進 (First 3-way)



(b) 3つ目の三叉路まで直進 (Second 3-way)



(c) 右折 (Third 3-way)



(d) 突き当たりまで直進 (straight road)



(e) 左折 (End)



(f) 突き当たりまで直進 (straight road)



(g) 停止 (End)

Fig.12 Behavior of the robot applied the proposed method