

# 視覚と行動の end-to-end 学習により経路追従行動を オンラインで模倣する手法の提案

-トポロジカルマップとシナリオに基づく経路選択機能の追加と検討-

○春山健太（千葉工大），藤原恆（千葉工大）馬場琉生（千葉工大）

石黒巧（千葉工大）上田隆一（千葉工大）林原靖男（千葉工大）

## A proposal for an online imitation method of path-tracking behavior by end-to-end learning of vision and action - Adding and consideration of path selection function based on a topological map and scenario -

○ Kenta HARUYAMA (CIT), Masaki FUJIWARA (CIT), Ryusei BABA (CIT),

Takumi ISHIGURO (CIT), Ryuichi UEDA (CIT), Yasuo HAYASHIBARA (CIT)

**Abstract:** We have proposed a method to select a route and move autonomously to a destination using camera images and target directions. In this paper introduces an additional method for creating target directions from camera images and autonomously moving to the destination without using metric maps. We confirmed the effectiveness of the method through the experiments using a real robot.

### 1. 緒言

自律移動ロボットの、経路計画や自己位置推定には事前に作成したメトリックマップが広く利用されている。しかし、人の往来や、環境の変化などの理由で、地図と環境の不一致により自律移動を継続できない場合がある。本研究グループでは、メトリックマップを利用しない自律移動の手段として、カメラ画像と目標とする進行方向を入力とした、経路を追従する行動を模倣学習により獲得する手法を提案し、実験により手法の有効性を検証してきた[1][2]。この手法では、LiDARなどをセンサ入力とする行動をカメラ画像と進行方向の情報（以後、目標方向と呼ぶ）を入力として模倣するように学習する。これにより、ロボットはFig.1のようなカメラ画像に基づいて経路を追従する行動を獲得できる。分岐路では、外部から与えられる、例えば「右折」などの目標方向によって経路を選択して走行する。ただし、目標方向をカメラ画像により生成していくなかつたため、カメラ画像のみで目的地まで移動することはできなかった。

本稿では、カメラ画像のみで目的地に移動するためには、カメラ画像から分岐路での目標方向を生成する機能を追加する。具体的には、島田ら[3]が提案したトポロジカルマップと「条件」や「行動」による経路の表現（以後、シナリオと呼ぶ）をこれまで提案した手法へ追加する。これにより、カメラ画像とトポロジカルマップから作成されるシナリオに基づいて、目的地まで自律移動するシステムを構築する。このシステムにより、事前に作成したメトリックマップを必要せずに、カメラ画像を入力として目的地まで自律移動できる可

能性がある。

メトリックマップを用いず、カメラ画像に基づいて自律移動を行う研究はいくつかある。Dhruvら[4]は大規模な事前学習モデルを用いて、自然言語による指示から、画像によるナビゲーションをend-to-endで行う手法を提案している。またmiyamotoら[5]はカメラ画像と深層学習による走行可能領域の検出とトポロジカルマップを用いたナビゲーション手法を提案している。これらの手法では、補助的ではあるが、Global Navigation Satellite System (GNSS) やホイールオドメトリといった情報を必要としている。センサ入力という観点で比較すると、本手法はカメラ画像のみで目的地まで移動できるという違いがある。本稿では、提案するシステムにより目的地までカメラ入力のみで自律移動できるかを、実ロボットを用いた実験により検証する。

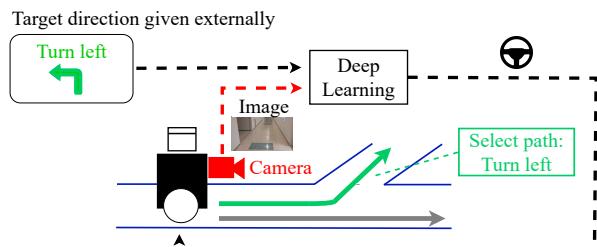


Fig.1 Path selection and following behavior based on camera images and target direction by imitation learning.

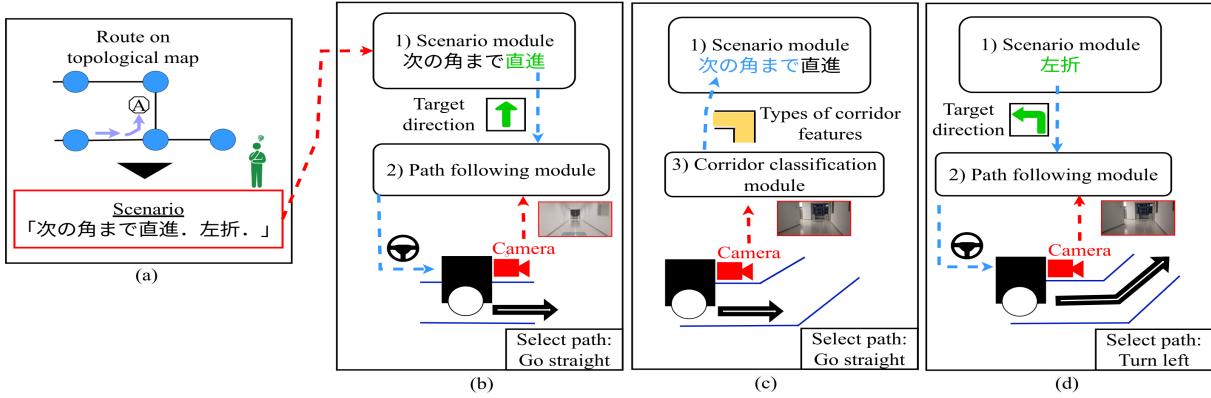


Fig.2 Overview of proposed system

## 2. 提案システム

提案するシステムについて述べる。提案するシステムでは、人間が作成した「次の角まで直進。左折」などのシナリオから指示された道順に従い、カメラ画像に基づいて目的地まで自律移動する。本章ではシステムの概要について述べた後、それぞれのモジュールの詳細を述べる。

Fig.2に提案システムの概要と一連の流れを示す。提案システムは、

- 1) シナリオを分解し、「条件」と「行動」を抽出するモジュール（以後、シナリオモジュールと呼ぶ）
- 2) カメラ画像と目標方向に基づいて、経路を追従するモジュール（以後、経路追従モジュールと呼ぶ）
- 3) カメラ画像を基に通路の特徴を分類するモジュール（以後、通路分類モジュールと呼ぶ）

の3つのモジュールで構成される。ロボットは下記のaからdの一連の流れにより、指示された経路に沿って目的地まで自律移動する

(a)トポロジカルマップ上の目的地に応じて、人が「条件」と「行動」で構成されるシナリオを作成する。例えば、図のAを目的地とするシナリオは「次の角まで直進。左折。」となる。

(b)作成したシナリオをシナリオモジュールへ入力する。シナリオモジュールは入力されたシナリオを分解し、「条件」と「行動」を抽出する。1つ目の条件と行動のセットは「次の角まで」と「直進」となる。この「直進」を目標方向として経路追従モジュールへ与える。経路追従モジュールは、カメラ画像と与えられた目標方向に基づいて、経路に沿って直進する。

(c)ロボットが角に近づくと、通路分類モジュールがカメラ画像に基づいて通路を「角」と分類して、それをシナリオモジュールに与える。シナリオモジュールはそれを基に「次の角まで」という条件を満たしたかを判定する。この場合は条件を満たしているため、2つ目の行動である「左折」へ遷移する。

(d)「左折」に基づいて、経路追従モジュールは経路に沿って角を左折する。

## 2.1 経路追従モジュール

前報[1][2]の提案手法に基づき構築した経路追従モジュールについて述べる。このモジュールは、事前に模倣学習させた環境で、カメラ画像に基づいて経路を追従するモジュールであり、分岐路では入力された目標方向によって経路を選択して走行する。

Fig.3に経路追従モジュールのシステムを示す。学習時は、2D-LiDARやオドメトリ、事前に作成したメトリックマップに基づいたルールベース制御器(ROS Navigation Stack[6])によって、設定した経路を走行する。その際、入力をカメラ画像と目標方向、出力をヨー方向の角速度とするデータを、0.2秒周期でデータセットに加える。このヨー方向の角速度は地図を用いたルールベース制御器が output する信号である。さらに、バッチサイズを8として教師データを抽出し、0.2秒の周期でオンラインで学習する。このデータセットへのデータの追加から学習までの1連の流れを1ステップとする。学習時の目標方向は、地図に基づいたルールベースの制御器から出力される信号である。データセットの収集には、藤原ら[2]が提案したデータセットの不均衡の改善、学習時における積極的な蛇行といった最も経路追従の成功率の高い手法を採用する。

学習後、モジュールはカメラ画像と目標方向を基に、ヨー方向の角速度を出力する。これにより経路を追従する。このとき、並進速度は0.2m/sである。なお、目標方向が「停止」の場合は、0.0m/sとなる。

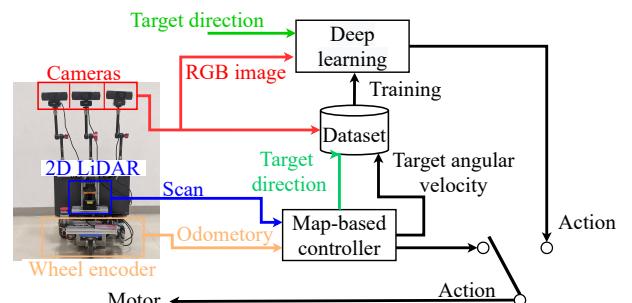


Fig.3 Path-following module system

## 2.2 シナリオモジュール

シナリオモジュールについて述べる。シナリオモジュールはトポロジカルマップから作成されたシナリ

オから「突き当たりまで」という「条件」や「左折」などの「行動」を解釈し、単語で構成された経路を分岐路での目標方向へ変換して出力する。

Fig.4 にトポロジカルマップの例とそれを基に作成されるシナリオを示す。トポロジカルマップは図中の青の通路の特徴的な箇所に配置されたノード、これらをつなぐ図中の緑のエッジで構成される。ノードはID、通路の特徴、接続されるエッジとその方向のデータが含まれ、エッジにはIDのデータのみが含まれている。シナリオはトポロジカルマップ上の目的地までの経路を、「条件」と「行動」に関する単語を組み合わせることで表現したものである。図の例では出発地点をエッジ2、目的地をノード2として、その間のエッジとノードを移動する。エッジ2からノード1は「三叉路まで」という条件と「直進」という行動、ノード1からエッジ1は「右折」という行動、エッジ1からノード1は「突き当たり（三叉路）まで」という条件と「直進」の行動で表現される。これらを統合すると、最終的に「三叉路まで直進。右折。突き当たりまで直進。停止。」が作成される。

次に作成されたシナリオを目標方向として変換する方法を述べる。目標方向への変換ではシナリオを句点ごとに分解後、「条件」と「行動」を示す言葉を抽出し、以下の項目に分けて登録する。

- 1) 通路の特徴 例として、三叉路、角など
- 2) 順番 例として、3つ目の、2番目のなど
- 3) 方向 例として、左手に、右手になど
- 4) 行動 例として、右折、停止など

シナリオの例は句点ごとに三叉路まで直進/ 右折/ 突き当たりまで直進/ 停止/ と分解される。1つ目の条件と行動は 1) 通路の特徴 三叉路、4) 行動 直進となる。2つ目の行動は 4) 行動：右折となる。この一連の処理を末尾まで行う。この「行動」を分岐路での目標方向に変換して、前述の経路追従モジュールへ与える。目標方向のデータ形式を Table 1 に示す。ここで、「三叉路まで」といった条件を満たしたかの判定は、後述する通路分類モジュールを用いて行う。

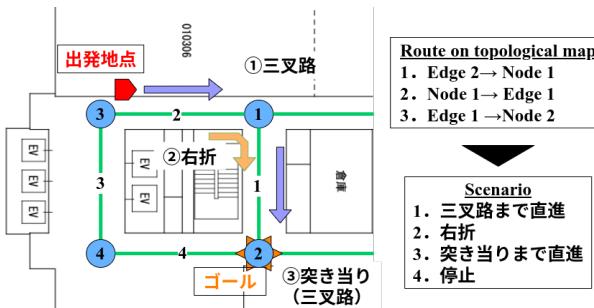


Fig.4 Example of topological map and created scenario

Table 1 Target direction and data for path-following module

Target direction	Data
Go straight	[1, 0, 0]
Turn left	[0, 1, 0]
Turn right	[0, 0, 1]
Stop	[0, 0, 0]

### 2.3 通路分類モジュール

通路分類モジュールについて述べる。このモジュールは、シナリオの「条件」を満たすかの判定に必要な通路の特徴を、カメラ画像を入力して分類する。通路分類モジュールの概要を Fig.5 に示す。このモジュールはフレーム数 16、画像サイズ  $64 \times 48$  の連続した画像データを入力とし、通路の特徴を分類した結果を出力とする。通路の特徴の分類は島田らの手法 [3] に倣い、Fig.6 に示した 8 つとする。このモジュールのネットワークアーキテクチャは Dhaivat らが提案する CNN と LSTM を組み合わせた LRCN[7] に倣って構築した。なお、CNN アーキテクチャには MobileNetV3-Large[8] を用いている。

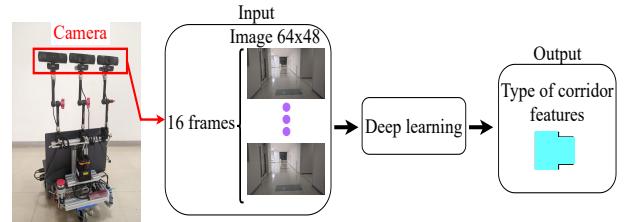


Fig.5 Overview of the corridor classification module

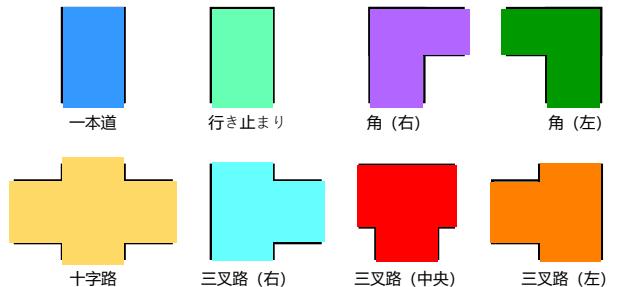


Fig.6 Types of corridor features

次に通路分類モジュールのデータセットの作成について述べる。データの作成では、経路追従モジュールの学習と同様に、地図に基づいたルールベース制御器によって経路を走行する。その際、フレーム数 16 の連続したカメラ画像と通路の分類ラベルを 1 組とし、0.125 秒周期でデータセットへ加える。分類ラベルのアノテーションは、Fig.7 に示すように、通路の特徴を予め地図に登録しておくことで、自動的に行う。

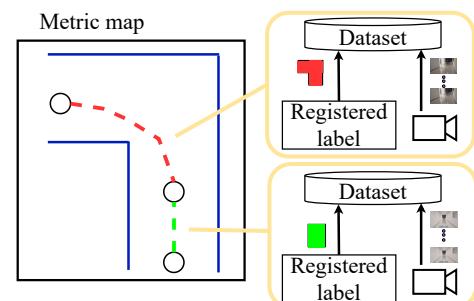


Fig.7 Classification labels registered in the metric map

学習に用いるデータセット内で、各クラスのデータ数が大きく異なる不均衡データは、分類に大きな影響を与える [9] とされている。そのため、本稿では学習する際に、データセット内のクラス間のデータ数によって重み付けを行うコストアプローチ [10] を導入して

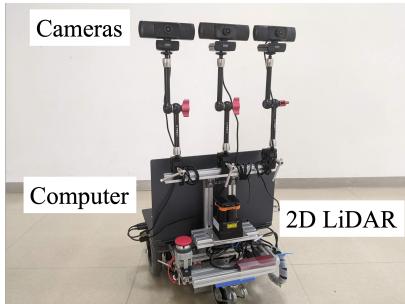


Fig.8 Experimental setup

いる。

### 3. 実験

実ロボットを用いて、提案するカメラ画像とシナリオに基づく経路追従システムにより、ロボットが目的地へ到達可能であるか検証する。

#### 3.1 実験装置

実験には Fig.8 で示すロボットを使用する。単眼ウェブカメラを 3 つ、2D-LiDAR(北陽電機 UTM-30LX)を 1 つ搭載している。制御用の PC には (GALLERIA GCR2070RGF-QC-G) を使用している。

#### 3.2 実験方法

実験環境として Fig.9 に示す千葉工業大学津田沼キャンパス 2 号館 3 階の廊下を用いる。経路追従モジュールの訓練および通路分類モジュールのデータセット収集では Fig.10 で示した a から n の経路を順番に走行する。実験では島田らが用いた 50 例のシナリオの中から、Fig.11 に示す 7 例を用いた。選定の基準は、Fig.9 の場所を対象としていること。ロボットが移動困難な狭い通路が含まれていないこと、「後ろを向く」など経路追従モジュールができない行動が含まれていないことである。

まずははじめに通路分類モジュールの訓練を行う。前述の経路を地図に基づいたルールベース制御器の出力を用いて、3 周し、データセットを収集する。収集したデータは、1, 2 周目を訓練データとし、3 周目をテストデータとする。それぞれのデータ数は、訓練データ 5781, テストデータ 2902 である。訓練はバッチサイズを 32 として、30 epoch 行った。訓練の結果、テストデータに対する Accuracy は 0.98 であった。

次に経路追従モジュールの訓練を行う。通路分類モジュールの訓練と同様の経路を、オンラインで模倣学習しながら 1 周走行する。その際のステップ数は 12000 であった。

2 つのモジュールを訓練後、シナリオを 1 例ずつ入力して、ロボットの挙動を観察する。実験では、ロボットをシナリオのスタート地点に移動して、自律移動を開始する。

#### 3.3 実験結果

Fig.12 に Fig.11(f) のシナリオを入力した実験の様子を示す。図に示すように、シナリオで指定された道順に従い、三叉路などの分岐路で適切に経路を選択して自律移動する様子が見られた。結果として、7 例すべての例でロボットが、指定された経路を追従して目的地へ到達した。以上の結果から、提案するカメラ画像とシナリオに基づいて、経路を追従して目的地まで自律移動するシステムの有効性が確認された。

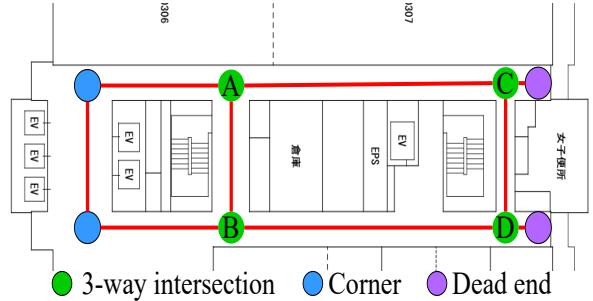


Fig.9 Experimental environment

### 4. 結言

本稿では、事前に作成したメトリックマップを用いず、カメラ画像とシナリオに基づいて経路を追従して目的地まで自律移動するシステムを提案した。そして、実ロボットを用いた実験により提案システムの有効性を検証した。実験では、提案システムにより、ロボットが目的地へ到達可能であることを確認した。

### 参考文献

- [1] 春山 健太 et al.: “視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案”. 日本機械学会ロボティクス・メカトロニクス講演会'22 予稿集, 2P2-L05, (2022).
- [2] 藤原柾 et al.: “視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案 - 実環境における経路選択機能の検証と学習時間の短縮化の検討”. 日本機械学会ロボティクス・メカトロニクス講演会'23 予稿集, 2P2-G06, (2023).
- [3] 島田滉己, 上田隆一, 林原靖男: “トポロジカルマップを用いたシナリオによるナビゲーションの提案 - シナリオに基づく実ロボットのナビゲーション”. 計測自動制御学会 SI 部門講演会 SICE2020 予稿集, 1H2-04, (2020).
- [4] Dhruv Shah et al.: “LM-Nav: Robotic Navigation with Large Pre-Trained Models of Language, Vision, and Action”. 6th Annual Conference on Robot Learning. 2022. URL: <https://openreview.net/forum?id=UW5A3SweAH>.
- [5] Ryusuke Miyamoto et al.: “Vision-Based Road-Following Using Results of Semantic Segmentation for Autonomous Navigation”. 2019 IEEE 9th International Conference on Consumer Electronics (ICCE-Berlin). 2019, pp. 174–179. doi: 10.1109/ICCE-Berlin47944.2019.8966198.
- [6] ROS Navigation Stack: *ROS Navigation Stack*. Accessed on 25.10.2023. URL: <https://github.com/ros-planning/navigation>.
- [7] Dhaivat Bhatt et al.: “Have I reached the intersection: A deep learning-based approach for intersection detection from monocular cameras”. 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2017, pp. 4495–4500. doi: 10.1109/IROS.2017.8206317.
- [8] Andrew Howard et al.: *Searching for MobileNetV3*. (2019). arXiv: 1905.02244 [cs.CV].
- [9] Harsurinder Kaur, Husanbir Singh Pannu, and Avleen Kaur Malhi: “A Systematic Review on Imbalanced Data Challenges in Machine Learning: Applications and Solutions”. ACM Comput. Surv. 52.4, (Aug. 2019). ISSN:

0360-0300. doi: 10.1145/3343440. URL: <https://doi.org/10.1145/3343440>.

- [10] Jie Xu et al.: “Fault Diagnosis on Imbalanced Data Using an Adaptive Cost-sensitive Multiscale Attention Network”. *2021 International Conference on Intelligent Technology and Embedded Systems (ICITES)*. 2021, pp. 77–82. doi: 10.1109/ICITES53477.2021.9637101.

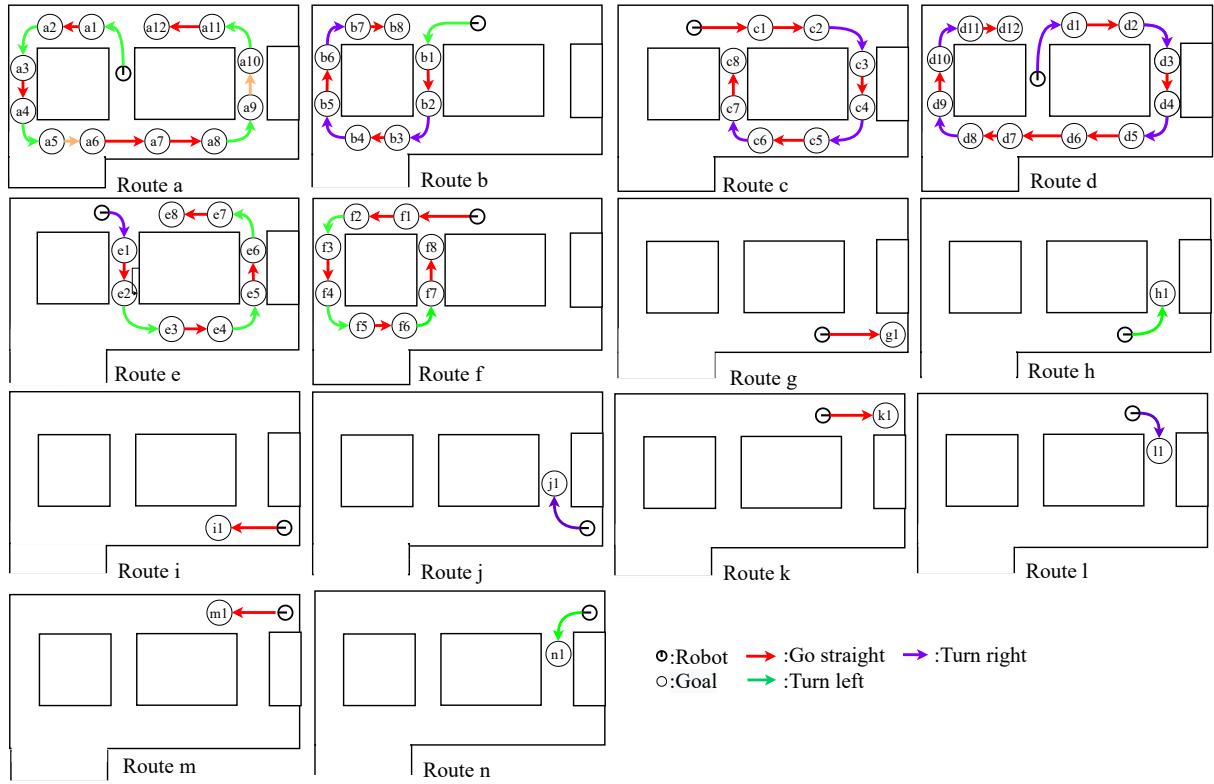


Fig.10 Route used for learning

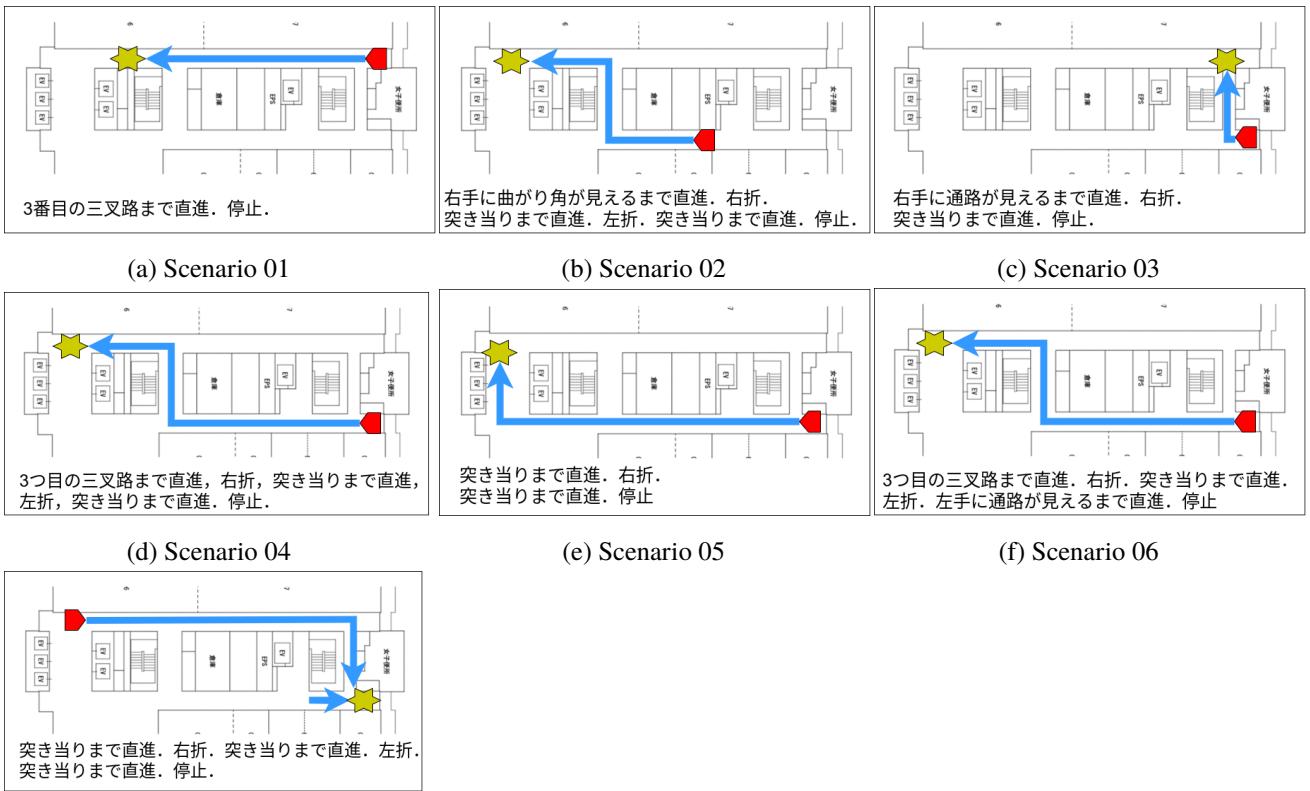


Fig.11 Scenarios used in the experiment



(a) 3つ目の三叉路まで直進 (First 3-way)



(b) 3つ目の三叉路まで直進 (Second 3-way)



(c) 右折 (Third 3-way)



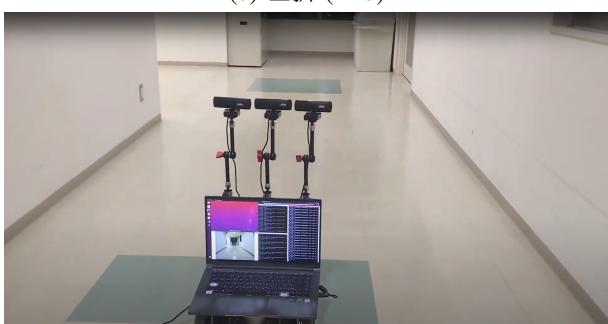
(d) 突き当たりまで直進 (Straight road)



(e) 左折 (End)



(f) 突き当たりまで直進 (Straight road)



(g) 停止 (End)

Fig.12 An example of the robot applied the proposed system